مكتب التكوين المهني و إنعاش الشغل

Office de la formation professionnelle et de la promotion du travail

مدن المهن و الكفاءات

Cités des Métiers et des Compétences

Direction Régionale : Casablanca – Settat *Cité des métiers et des compétences Nouaceur*

Contrôle continu N° 1 : Moteur NLP
Année 2025/2026

Filière : Intelligence Artificielle
Niveau : TS
Groupe : DIA_IAODC_TS_201
Nom et Prénom :.....

Durée : 2H
Variante : A
Barème : .../20

Partie I : QCM (10 pts)

1. En Regex, que fait le motif `\d+` ? (1 pt)
   ☐ Il sélectionne n'importe quelle lettre.
   ☐ Il sélectionne un ou plusieurs chiffres.
   ☐ Il sélectionne le début de la phrase.
   ☐ Il supprime les espaces vides.

2. Quelle est l'utilité principale de `BeautifulSoup` ? (1 pt)
   ☐ Envoyer des requêtes Internet.
   ☐ Extraire des infos depuis une page HTML.
   ☐ Faire fonctionner un vrai navigateur web.
   ☐ Dessiner des graphiques en HTML.

3. Qu'est-ce que la "Tokenisation" ? (1 pt)
   ☐ Traduire le texte dans une autre langue.
   ☐ Découper une phrase en une liste de mots.
   ☐ Corriger les fautes d'orthographe.
   ☐ Transformer les mots en vecteurs mathématiques.

4. Que fait la regex `<.*?>` ? (1 pt)
   ☐ Capture le texte le plus long entre chevrons
   ☐ Capture le texte le plus court entre chevrons
   ☐ Capture seulement les chiffres
   ☐ Supprime les espaces

5. L'avantage principal des réseaux LSTM est : (1 pt)
   ☐ Ils ignorent l'ordre des mots
   ☐ Ils mémorisent le contexte long terme
   ☐ Ils fonctionnent sans données
   ☐ Ils s'entraînent uniquement sur images

6. Quelle est la différence entre un Token et un Embedding ? (0.5 pt)
   ☐ Aucun
   ☐ Un Embedding est un vecteur, un Token est un index
   ☐ L'embedding est une phrase complète, un Token est un verb
   ☐ Le token est un synonyme de mot

7. Prenons le mot "Imprévisible". Il contient "im-" (négation) et "prévisible" (qui peut être prévu). Ici, "im-" est un : (1 pt)
   ☐ Phonème.
   ☐ Morphème.
   ☐ Stop Word.
   ☐ Caractère spécial.

8. Vous voulez nettoyer un texte pour enlever les balises HTML comme `<div>`. Quelle fonction Python du module `re` utilisez-vous ? (0.5 pt)
   ☐ `re.search()`
   ☐ `re.match()`
   ☐ `re.sub()`
   ☐ `re.split()`

9. Vous entraînez un modèle. Vous avez 99% de réussite en entraînement (Train) mais seulement 60% sur les nouvelles données (Validation). Quel est le problème ? (1 pt)
   ☐ Underfitting.
   ☐ Overfitting.

☐ Le dataset est trop grand.
☐ C'est un résultat normal.

10. Quelle est la différence entre Stemming et Lemmatisation ? (1 pt)
☐ La Lemmatisation ne fonctionne que sur l'anglais.
☐ Le Stemming est plus lent à exécuter que la Lemmatisation.
☐ Le Stemming coupe le mot, la Lemmatisation trouve la racine réelle.
☐ Les deux méthodes font la même chose.

11. Pourquoi supprime-t-on souvent les "Stop Words" (le, la, de, un...) ? (1 pt)
☐ Car ils sont très fréquents et portent peu de sens spécifique.
☐ Car ils sont trop longs à lire pour l'ordinateur.
☐ Car ils provoquent des erreurs de syntaxe Python.
☐ On ne doit jamais les supprimer.

Exercice 1 : Monitoring de prix (4pts)

```
import requests
from bs4 import BeautifulSoup
import pandas as pd

def scraper_livres():
    url = "http://books.maktaba.com/" # Site d'entrainement
    data_list = []
    (1pt) # 1. Requete au site
    # --- TO DO # Remplacer None par votre code pour récupérer la page
    response = None

    ..............................................................
    if response.status_code == 200:
        (1pt) # 2. Parsing HTML (transforme le HTML en objet manipulable.)
        soup = Soup  # --- TO DO: Remplacer Soup par votre code

    ..............................................................
        (1pt) #3. Ciblage des elements (Chaque livre est dans une balise ==>
           <article class="product_pod">)
        # --- TO DO : Trouver tous les articles
        articles = all_articles  # Remplacer par votre code

    ..............................................................
        for article in articles:

            # Extraction du titre (qui est dans l'attribut 'title' de la
               balise <a> dans <h3>)

            titre = article.h3.a['title']
            # Extraction du prix (dans <p class="price_color">)
           (0.5pt) # --- TO DO : Recuperer le texte du prix ---
            prix_brut = "$0.00"  # Remplacer par votre code

    ..............................................................
            # Nettoyage: enlever le symbole $
            prix_net = prix_brut.replace('$', '')

            (0.5pt) # --- TO DO Ajout titre et le prix_net au tableau
               data_list
```

```
    ..........................................................
        df = pd.DataFrame(data_list)
        print(df.head())

    else:
        print("Erreur de connexion au site.")

# Lancer le programme
scraper_livres()
```

Exercice 2 : Analyse de Sentiment avec RNN et Regex (6pts)

```
import re
import numpy as np
from tensorflow.keras.preprocessing.text import Tokenizer
from tensorflow.keras.preprocessing.sequence import pad_sequences
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Embedding, SimpleRNN, Dense

# --- 1. Dataset (Un export API JSON) ---
reviews_db = [
    {"id": 101, "source": "Web", "text": "<div>SUPER produit !!! J'adore.</
       div>"},
    {"id": 102, "source": "App", "text": "C'est nul, vraiment mauvais... <br>
       "},
    {"id": 103, "source": "Email", "text": "Pas mal, assez satisfait dans l'
       ensemble."},
    {"id": 104, "source": "Web", "text": "HORRIBLE !!! A fuir absolument 0/10
       "},
    {"id": 105, "source": "App", "text": "Excellent service, merci :) <span
       class='user'>Bob</span>"}
]

# --- 2. Labels pour sentiment (1 = positif, 0 = négatif)
labels = [1, 0, 1, 0, 1]

# --- 3. Prétraitement avec Regex ---
def nettoyer_texte(texte):
    (1pt)#  --- TO DO : # 1. Supprimer les balises HTML (<div>, <br>, ...)

    texte = re.sub(r'....................', ' ', texte)
    (0.5pt)#  --- TO DO : Mettre en minuscules ---

    texte = texte. ................()
    # ---- TO DO Supprimer tout ce qui n'est pas une lettre ou un espace

    texte = re.sub(r'......................', '', texte)

    # Supprimer espaces multiples
    texte = re.sub(r'\s+', ' ', texte).strip()
    return texte

(1pt)#  --- TO DO : Appliquer le nettoyage à tous les textes reviews_db ---
```

```
texts = [.............................................................]

# --- 4. Tokenization et padding ---
tokenizer = Tokenizer(num_words=50)
(0.5pt)#  --- TO DO : Adapter le tokenizer sur le texte nettoyé ---
tokenizer. ...............................(................)

sequences = tokenizer.texts_to_sequences(texts)
X = pad_sequences(sequences, maxlen=10)
y = np.array(labels)

(1pt)#  --- 5. Construction du modèle RNN ---

model = Sequential()
model.add(....................(input_dim=50, output_dim=8, input_length=10))

model.add(....................(8))
model.add(Dense(1, activation='sigmoid'))
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['
   accuracy'])

# --- 6. Entrainement ---
(1pt)#  --- TO DO : Entrainer le modèle ---
model.fit(............, ..............., epochs=50, verbose=1)

# --- 7. Prédiction sur de nouvelles phrases ---
nouvelles_phrases = [
    "<div>J'adore ce produit !</div>",
    "Service vraiment mauvais..."
]
# Prétraiter les nouvelles phrases
X_new = pad_sequences(tokenizer.texts_to_sequences([
nettoyer_texte(p) for p in nouvelles_phrases]), maxlen=10)

(1pt)# --- TO DO : Faire les prédictions et afficher POSITIF/NEGATIF ---
predictions = model. ..............(.............)

for phrase, pred in zip(nouvelles_phrases, predictions):
    sentiment = "POSITIF" if ..................... else "NEGATIF"

    print(f"{phrase} --> {sentiment}")
```