مكتب التكوين المهني و إنعاش الشغل

Office de la formation professionnelle et de la promotion du travail

Direction Régionale : Casablanca – Settat *Cité des métiers et des compétences Nouaceur*

Contrôle continu N°2 : Moteur NLP
Année 2025/2026

Filière : Intelligence Artificielle
Niveau : TS
Groupe : DIA_IAODC_TS_201
Nom et Prénom :.....

Durée : 1H30
Variante : B
Barème : .../20

Partie(QCM) : Cocher la bonne réponse (18 points)

1) Dans le JSON suivant, combien y a-t-il d'intentions ? (1.5 pts)

```
{
 "intents": [
   {"tag": "salutation"},
   {"tag": "competences"},
   {"tag": "debouches"}
 ]
}
```

☐ 1
☐ 2
☐ 3
☐ 4

2) RAG (Retrieval-Augmented Generation) permet de : (1 pt)
☐ Supprimer l'étape d'entraînement
☐ Générer sans contexte
☐ Combiner recherche documentaire et génération
☐ Remplacer les Transformers

3) Pour extraire toutes les images avec BeautifulSoup : (1 pt)
☐ soup.find_all("a")
☐ soup.find_all("img")
☐ requests.get(url).json()
☐ pandas.read_html(url)

4) Le fine-tuning consiste à : (1 pt)
☐ Entraîner un modèle depuis zéro
☐ Adapter un modèle pré-entraîné à une tâche spécifique
☐ Supprimer certaines couches et éviter l'overfitting
☐ Réduire le dataset

5) L'avantage principal des réseaux LSTM est : (1 pt)
☐ Ils ignorent l'ordre des mots
☐ Ils mémorisent le contexte long terme
☐ Ils fonctionnent sans données
☐ Ils s'entraînent uniquement sur images

6) Séquence correcte pour entraîner un modèle TensorFlow : (1.5 pt)

☐ predict → compile → fit
☐ compile → fit → evaluate
☐ fit → compile → evaluate
☐ evaluate → predict → fit

7) Le mécanisme d'Attention permet de : (1 pt)

☐ Supprimer les stop words automatiquement
☐ Donner plus d'importance aux mots pertinents
☐ Réduire la taille du vocabulaire
☐ Remplacer la tokenisation

8) Quelle fonction du module `re` permet de supprimer des balises HTML ? (1.5 pt)

☐ re.search()
☐ re.match()
☐ re.split()
☐ re.sub()

9) Quel est le principal risque d'un modèle NLP entraîné uniquement sur des textes en français standard pour analyser des tweets en darija ? (1 pt)

☐ Sous-représentation linguistique et biais discriminatoire
☐ Augmentation de la vitesse de traitement
☐ Amélioration de la précision
☐ Réduction de la consommation mémoire

10) Un problème courant des LLMs est : (1 pt)

☐ Sur-apprentissage aux images
☐ Hallucinations
☐ Absence d'embeddings
☐ Manque de tokenisation

11) L'avantage principal de RAG est : (1 pt)

☐ Réduire la Hallucination du modèle
☐ Améliorer la factualité des réponses
☐ Supprimer le tokenizer
☐ Éviter l'overfitting

12) La similarité cosinus entre deux vecteurs TF-IDF proches de 1 indique : (0.5 pt)

☐ Une forte similarité sémantique
☐ Une absence totale de mots communs
☐ Une différence de longueur de texte
☐ Un vocabulaire thématique partagé

13) Quelle est la différence entre un Token et un Embedding ? (1 pt)

☐ Un embedding est une phrase complète, un token est une unité de texte
☐ Un token est un synonyme
☐ Un embedding est un vecteur numérique, un token est une unité de texte
☐ Les deux sont identiques

14) À quoi sert `tf.argmax()` dans un chatbot ? (0.5 pt)

☐ Nettoyer le texte
☐ Encoder les labels
☐ Choisir l'intention la plus probable
☐ Entraîner le modèle

15) Le pré-entraînement d'un LLM se fait généralement sur : (1 pt)
☐ Un petit dataset annoté
☐ Des données massives non annotées
☐ Des images uniquement
☐ Des données numériques structurées

16) Quel est l'apport majeur de l'architecture Transformer dans le traitement du langage naturel ? (0.5 pt)
☐ Il ignore l'ordre des mots
☐ Il traite chaque mot séparément sans dépendance
☐ Il capture les dépendances globales dans la phrase
☐ Il ne nécessite pas de données d'entraînement

17) Dans Self-Attention, Q, K, V signifient : (1 pt)
☐ Query, Kernel, Vector
☐ Question, Knowledge, Value
☐ Query, Key, Value
☐ Queue, Key, Variable

18) Que fait cette instruction ? (1 pt)

```
tokenizer = AutoTokenizer.from_pretrained("camembert-base")
```

☐ Charge un modèle de classification
☐ Charge un tokenizer pré-entraîné
☐ Entraîne CamemBERT
☐ Télécharge un dataset

Partie B : Correspondance des concepts fondamentaux en TAL (2 points)

Reliez chaque terme NLP (Colonne A) à sa définition ou exemple correct (Colonne B). Écrivez la lettre correspondante dans la case.

	Terme		**Définition / Exemple**
3	Tokenisation	C	Découpage d'une phrase en unités lexicales : `["Le", "gouvernement", "investira", "dans", "l'", "éducation"]`
7	Transformer	G	Ajustement d'un modèle pré-entraîné sur une tâche spécifique avec un petit jeu de données
1	Lemmatisation	A	Architecture neuronale reposant uniquement sur des mécanismes d'attention (ex. *BERT*, *GPT*)
5	Racinisation (stemming)	E	*« éducation »* → *« éduc »* (troncature algorithmique)
8	Ingénierie de prompt (prompt engineering)	H	Conception d'instructions ou de questions pour guider un modèle de langue vers la réponse souhaitée
2	Mécanisme d'attention	B	*« investira »* → *« investir »* (forme canonique issue du dictionnaire)
4	Vectorisation / Plongement (embedding)	D	Transformation d'un texte en une représentation numérique dense (ex. *Word2Vec*, *BERT*)
6	Fine-tuning	F	Pondération dynamique des différentes parties d'une séquence pour se concentrer sur les informations pertinentes